Так. Опишу свои попытки разобраться в том, как компилятор GCC работает с массивами и указателями.

С чего все началось.

С простого задания «Описать трёхмерный целочисленный массив, размером 3х3х3 и вывести элемент с индексом [1][1][1] при помощи арифметики указателей.» Я, недолго думая, сделал это так:

```
int cube[3][3][3];

int *ptr = &cube[0][0][0];

cube[1][1][1] = 777;

int i = 1, j = 1, k = 1;

std::cout << *(ptr + i*3*3 + j*3 + k) << "\n";
```

Идея заключается в присвоении указателю адреса первого элемента массива и отступить от него на соответствующее смещение.

Первый индекс шагает на 3*3 элементов (то есть размером 2-мерного массива)

Второй шагает на 3 элемента.

Третий отступает по элементу.

Преподаватель сказал, что такая адресация не очень прозрачная. И пожалуй был прав. (зато такое представление отражает тот факт, что массив выделенный на стэке идет «сплошняком», то есть непрерывно, элемент за элементом. ИМХО).

Преподаватель предложил такой вариант:

```
printf("\%d\n", *(*(cube + 1) + 1) + 1));
```

Тут у меня в голове возник «Kernel Panic». Как так?! Ведь *cube* это адрес (в моем понимании адрес == указатель, позже станет понятно почему), прибавив к адресу значение (то есть увеличив адрес) мы получим адрес, и наконец разыменовав адрес мы должны получить значение! А у нас там еще целых 2 разыменования, мы же по-любому вылезем за пределы программы (в смысле за пределы диапазона адресов выделенных в оперативной памяти для нашей программы)!!! Так бы и случилось, если бы сиbе был самым обычным указателем, как например *int* ****ptr*;. Однако *cube* не совсем обычный указатель. Да *cube* == *адрес_начала_массива*, и служит указателем начала массива, но компилятор GCC знает что это сube это массив и потому работает с ним несколько по-другому.

Оговорюсь сразу, что что бы достоверно узнать КАК компилятор работает с массивом, нужно изучать сорсы компилятора или реверсить. Все мои мысли являются только догадкой.

Итак. Первое, что я сделал, это накидал такой код:

```
#include <stdio.h>

int main(int argc, char* argv[]){
	int a = 10;
	int cube[3][3][3] = {
			 {{1, 2, 3}, {4, 5, 6}, {7, 8, 9}},
			 {{10, 11, 12}, {13, 14, 15}, {16, 17, 18}},
			 {{19, 20, 21}, {22, 23, 24}, {25, 26, 27}}
	};
	int *p = &a;
	a = *p + 10;
	int *ptr = &cube[0][0][0];
	printf("%d\n", *(ptr + 1*3*3 + 1*3 + 1));
	printf("%d\n", *(*(*(cube + 1) + 1) + 1));
	printf("%d\n", *(*(*(cube + 2) + 1));
```

```
printf("%p \mid n", *(cube + 1)); return 0;
```

Теперь я думал, что запущу ее в отладчике и увижу как все эти разыменования могут выдавать корректный результат.

Но не тут то было.

По порядку.

Первое, что мы увидим в отладчике (или можно использовать какой-либо дизассемблер), это инициализацию переменных. Все переменные у нас локальные, используются только в олной функции, потому место для них выделяется на стэке.

однои функции, п	дной функции, потому место для них выделяется на стэке.									
0000000000401550	55	push rbp								
0000000000401551	48:89E5	mov rbp,rsp								
0000000000401554	48:81EC A0000000	sub rsp,A0								
000000000040155B	894D 10	mov dword ptr ss:[rbp+10],ecx								
000000000040155E	48:8955 18	mov qword ptr ss:[rbp+18],rdx								
0000000000401562	E8 09020000	call t.401770								
0000000000401567	C745 EC 0A000000	mov dword ptr ss:[rbp-14],A								
000000000040156E	C745 80 01000000	mov dword ptr ss:[rbp-80],1								
0000000000401575	C745 84 02000000	mov dword ptr ss:[rbp-7C],2								
000000000040157C	C745 88 03000000	mov dword ptr ss:[rbp-78],3								
0000000000401583	C745 8C 04000000	mov dword ptr ss:[rbp-74],4								
000000000040158A	C745 90 05000000	mov dword ptr ss:[rbp-70],5								
0000000000401591	C745 94 06000000	mov dword ptr ss:[rbp-6C],6								
0000000000401598	C745 98 07000000	mov dword ptr ss:[rbp-68],7								
000000000040159F	C745 9C 08000000	mov dword ptr ss:[rbp-64],8								
00000000004015A6	C745 AO 09000000	mov dword ptr ss:[rbp-60],9								
00000000004015AD	C745 A4 0A000000	mov dword ptr ss:[rbp-5C],A								
00000000004015B4	C745 A8 0B000000	mov dword ptr ss:[rbp-58],B								
00000000004015BB	C745 AC 0C000000	mov dword ptr ss:[rbp-54],C								
00000000004015C2	C745 BO 0D000000	mov dword ptr ss:[rbp-50],D								
00000000004015C9	C745 B4 0E000000	mov dword ptr ss:[rbp-4C],E								
00000000004015D0	C745 B8 0F000000	mov dword ptr ss:[rbp-48],F								
00000000004015D7	C745 BC 10000000	mov dword ptr ss:[rbp-44],10								
00000000004015DE	C745 CO 11000000	mov dword ptr ss:[rbp-40],11								
00000000004015E5	C745 C4 12000000	mov dword ptr ss:[rbp-3C],12								
00000000004015EC	C745 C8 13000000	mov dword ptr ss:[rbp-38],13								
00000000004015F3	C745 CC 14000000	mov dword ptr ss:[rbp-34],14								
00000000004015FA	C745 D0 15000000	mov dword ptr ss:[rbp-30],15								
0000000000401601	C745 D4 16000000	mov dword ptr ss:[rbp-2C],16								
0000000000401608	C745 D8 17000000	mov dword ptr ss: [rbp-28],17								
000000000040160F	C745 DC 18000000	mov dword ptr ss: [rbp-24],18								
0000000000401616	C745 E0 19000000	mov dword ptr ss:[rbp-20],19								
000000000040161D	C745 E4 1A000000	mov dword ptr ss:[rbp-1C],1A								
0000000000401624	C745 E8 1B000000	mov dword ptr ss:[rbp-18],1B								

Немного инфы. Регистр rsp (полагаю sp – stack pointer) всегда указывает на вершину стэка. Стэк работает по принципу LIFO (last in, first out), то есть последнее значение которое в него положили, будет извлечено первым. Стэк растет в сторону меньших адресов (от 0хFFFFFFF до 0х00000000 (для x32 систем, для x64 расширьте значения до 8 байт)). Инструкция push помещает значение на вершину стэка (и соответственно *уменьшает* значение rsp), инструкция рор снимает значение с вершины стэка, *увеличивая* rsp. Взглянем на ассемблерный код.

```
push rbp
mov rbp, rsp
sub rsp, A0
```

Это вполне стандартный пролог, который можно встретить в начале большинства функций. Регистр rbp (полагаю bp – base pointer) в данном случае используется, как указатель кадра стэка. Деление на кадры условное, чтобы было удобней обращаться к локальным переменным и аргументам функции (но это не точно).

Командой push rbp мы сохраняем значение регистра в на вершине стэка. То есть сохраняем адрес предыдущего кадра стэка, чтобы потом, после того как наша функция отработает вернуть стэк в исходное состояние.

Командой mov rbp, rsp, помещаем указатель на вершину стэка в регистр rbp, тем самым обозная начало кадра стэка нашей функции.

Командой sub rsp, A0, увеличиваем значение регистра rsp на 0хA0 (160), тем самым резервируем место для наших локальных переменных. На вскидку нам нужно 4*27 байт для массива, 4 байта для переменной а, 8 байт для указателя, итого 120 байт. Компилятор

выделил больше, но наверняка у него были причины, больше не меньше (полагаю еще может на выравнивание потребоваться).

Сразу после инструкции call идет длинная череда присваиваний. Это как раз инициализация переменных. К примеру mov [rbp-14], А означает что по адресу rbp-14 нужно поместить значение 10 (0xA). Это инициализация переменой int a = 10; То есть мы знаем адрес a и он равен rbp-14. Как можно было заметить [] это и есть операция разыменования.

Сразу за инициализацией переменной **a**, следует ицициализация массива **cube**. Его елементы расположатся с адреса rbp-80 до rbp-14. После инициализации стэк будет выглядеть так:

Переменная а имеет адрес 0x61FE3C. По идее мы потом должны будем увидеть этот адрес в ячейке памяти отведенной под указатель р (ведь int * = &a;).

```
mov dword ptr ss:[rbp-20],19
mov dword ptr ss:[rbp-1C],1A
mov dword ptr ss:[rbp-18],1B
lea rax,qword ptr ss:[rbp-14]
000000000004016161
                          C745 E0 19000000
                           C745 E4 1A000000
000000000040161D
                           C745 E8 1B000000
000000000040162B
                           48:8D45 EC
                                                     mov qword ptr ss:[rbp-8],rax
mov rax,qword ptr ss:[rbp-8]
mov eax,dword ptr ds:[rax]
                           48:8945 F8
0000000000040162F
0000000000401633
                           48:8B45 F8
0000000000401637
                           8B00
0000000000401639
                           83C0 0A
                                                     add eax, A
                           8945 EC
                                                     mov dword ptr ss:[rbp
000000000040163C
                                                     lea rax, qword ptr ss:[rbp-80]
mov qword ptr ss:[rbp-10], rax
mov rax, qword ptr ss:[rbp-10]
000000000040163F
                           48:8D45 80
0000000000401643
                           48:8945 FO
0000000000401647
                           48:8B45 F0
000000000040164B
                           48:83C0 34
                                                      add rax,34
000000000040164F
                           8B00
                                                     mov eax, dword ptr ds:[rax]
0000000000401651
                           89C2
                                                      mov edx,eax
                                                     lea rcx, qword ptr ds: [404000]
0000000000401653
                           48:8D0D A6290000
000000000040165A
                           E8 41150000
                                                      call <JMP.&printf
                                                      lea rax,qword ptr ss:[rbp-80]
000000000040165F
                           48:8D45 80
0000000000401663
                           48:83C0 34
                                                      add rax,34
                                                     mov eax, dword ptr ds:[rax]
00000000000401667
                           8800
0000000000401669
                           89C2
                                                     mov edx, eax
                                                     lea rcx,qword ptr ds:[404000]
call <JMP.&printf>
lea rax,qword ptr ss:[rbp-80]
                           48:8D0D 8E290000
000000000040166B
0000000000401672
                           E8 29150000
0000000000401677
                           48:8D45 80
                           48:83C0 4C
0000000000040167B
                                                      add rax,40
                                                      mov eax,dword ptr ds:[rax]
000000000040167F
                           8800
0000000000401681
                                                     mov edx, eax
                           89C2
                                                     lea rcx,qword ptr ds:[404000]
call <JMP.&printf>
lea rax,qword ptr ss:[rbp-80]
0000000000401683
                           48:8D0D 76290000
                           E8 11150000
000000000040168A
000000000040168F
                           48:8D45 80
                                                      add rax,24
0000000000401693
                           48:83C0 24
0000000000401697
                           48:89C2
                                                      mov rdx,rax
000000000040169A
                           48:8D0D 63290000
                                                      lea rcx, qword ptr ds: [404004]
00000000004016A1
                                                      call <JMP.&printf>
                           E8 FA140000
00000000004016A6
                           B8 00000000
                                                      mov eax,0
00000000004016AB
                           48:81C4 A0000000
                                                      add rsp,A0
00000000004016B2
                                                      pop rbp
00000000004016B3
```

Сразу за инициализацией массива видим следующие инструкции:

lea rax, [rbp-14] mov [rbp-8], rax

Инструкция lea (load effective address по-моему) помещает вычисленный *адрес* в регистр гах (в отличие от инструкции mov которая помещает *значение*). А адрес rbp-14 принадлежит переменной **a**. То есть после инструкции lea rax, [rbp-14] в регистре гах будет лежать адрес переменной **a**. Следующая инструкция поместит содержимое регистра гах (то есть адрес переменной) в память по адресу rbp-8. Этот адрес и принадлежит указателю **p**. Взглянем на стэк после этих инструкций.

		Шестнадцатеричное								ASCII						
0000000000061FDBC 0	0 0	00	00	08	97	2000	0000	1006	1EDI	241	000	2000	0000	2000	100	/Dan 2000000000000000000000000000000000000
000000000061FDBC 0	0 0	00 0	00	01	d L	0000	0000	0000	TLD	orl :	= 000	JUUU	0000	JUUD	100	(ПОЛЬЗОВАТЕЛЬСКИЕ ДАГ
000000000061FDDC 0	4 0	00 0	00	05	00	00	00	06	00	00	00	07	00	00	00	
000000000061FDEC 0	8 0	00 0	00	09	00	00	00	OA	00	00	00	OB	00	00	00	
000000000061FDFC 0																
000000000061FE0C 1	0 0	00 0	00	11	00	00	00	12	00	00	00	13	00	00	00	
000000000061FE1C 1																
000000000061FE2C 1																
000000000061FE3C 0	A O	00	00	EO	14	В1	00	00	00	00	00	3C	FE	61	00	à.±<þa.

Указатель занимает 8 байт. В нем лежит адрес переменной **а**. Все как и ожидалось (за исключением того, что я ожидал увидеть 3CFE6100 00000000, видимо каки-то нюансы работы процессора со стэком). Почему порядок байт изменен? Процессор работает с памятью в порядке little endian(от младшего байта к старшему).

Далее

```
mov rax, [rbp-8] //получаем адрес указателя mov eax, dword [rax] //mo самое разыменование *p
```

//dword указывает что хотим прочитать 4 байта

Вот именно так в моей голове происходит разыменование любого указателя.

Если даже это будет тройной указатель, например int ***p; операция разыменования ***p в инструкциях процессора будет выглядеть примерно так:

mov rax [ptr_address]
mov rax, [rax]

mov rax, [rax]

mov eax, dword [rax]

(Может в конце добавлю код с тройным указателем и проверю)

Далее

lea rax, [rbp-80] //получаем адрес массива mov [rbp-10], rax //*ptr = &cube[0][0][0];

mov rax, [rbp-10] //и все таки нам нужен адрес массива

add rax 34 //добавляем смещение до нужного элемента

mov eax, dword [rax] //получаем значение элемента массива, разыменовывая его адрес //dword указывает что хотим прочитать 4 байта

Вот так. Все вот это выражение *(ptr + 1*3*3 + 1*3 + 1) преобразовалось в последние 3 строки ассемблерного кода. GCC еще на этапе компиляции рассчитал смещение и отпимизировал код.

Неужели и с этим выражением *(*(cube + 1) + 1) + 1)) он поступит также? .

Следующий фрагмент кода

mov edx, eax

lea rcx, ds:[404000]

call printf

Здесь у нас передача параметров и вызов функции printf. Согласно соглашению о вызовах функций для ОС Windows x64 параметры передаются через регистры rcx, rdx, r8, r9 остальные параметры (если ux > 4) через стэк, если я все правильно помню. В нашем случае это выглядит как то так: printf(rcx, rdx). В rdx у нас адрес элемента массива, в rcx указатель на строку «%d\n». (Кстати в соглашении о вызове в Linux x64 параметры передаются через регистры rdi, rsi, rdx, rcx. Опять же могу ошибаться)

Далее

```
lea rax, [rbp-80] //адрес массива add rax, 34 //смещение mov eax, dword [rax] //разыменование
```

Вот и выражение *(*(cube + 1) + 1) + 1)) свелось к получению адреса массива, сдвигу до нужного элемента и разыменованию.

```
Вызов функции ничем не отличается
Далее. *(*(cube + 2)) + 1))
lea rax, [rbp-80]
                        //адрес массива
add rax, 34
                        //смещение
mov eax, dword [rax]
                        //разыменование
вызов функции
Наконец добрались до *(cube + 1)
lea rax, [rbp-80]
                        //адрес массива
add rax, 24
                        //смещение
вызов функции
И все? Даже разыменования нет?! Но ведь оно же явно вызывается!
Очевидно, что пользование отладчиком, не прольет свет на то, как же компилятор
обрабатывает арифметику указателей касательно массивов.
mov eax, 0
            //return 0
add rsp, A0 //возвращаем стэк в исходное состояние
pop rbp
             //возвращаем указатель на кадр стэка вызывающе функции
ret
             //переходим по адресу возврата
Так хотел добавить тройной указатель.
Сделал.
#include <stdio.h>
int main(int argc, char* argv∏){
       int a = 10;
       int \ cube[3][3][3] = \{
              {{1, 2, 3}, {4, 5, 6},{7, 8, 9}},
              {{10, 11, 12}, {13, 14, 15},{16, 17, 18}},
              {{19, 20, 21}, {22, 23, 24},{25, 26, 27}}
       };
       int *p = &a;
       a = *p + 10;
       int *ptr = &cube[0][0][0];
       int **m = \&ptr;
       int ***q = \&m;
       printf("\%d\n", *(ptr + 1*3*3 + 1*3 + 1));
       printf("\%d\n", *(*(cube + 1) + 1) + 1));
       printf("\%d\n", *(*(cube + 2)) + 1));
       printf("\%p\n", *(cube + 1));
       printf("\%d \mid n", ***q);
       return 0;
      00000000004016AE
                             48:8D45 80
                                                    lea rax, qword ptr ss:[rbp-80]
                                                    add rax,24
mov rdx,rax
                             48:83C0 24
      00000000004016B2
      0000000000401686
                             48:89C2
                                                    lea rcx,qword ptr ds:[404004]
      0000000000401689
                             48:8D0D 44290000
      00000000004016C0
                             E8 0B150000
                                                    call <JMP.&printf>
      00000000004016C5
                                                    mov rax, qword ptr
                                                                         :[rbp-10]
                             48:8B45 F0
                                                   mov rax, qword ptr ds: [rax]
mov rax, qword ptr ds: [rax]
      00000000004016C9
                             48:8B00
      00000000004016CC
                             48:8B00
      00000000004016CF
                             8B00
                                                   mov eax, dword ptr
      00000000004016D1
                             89C2
                                                    mov edx,eax
                                                   lea rcx,qword ptr ds:[404004]
call <JMP.&printf>
                             48:8D0D 2A290000
      00000000004016DA
                             E8 F1140000
```

Красивое, логичное тройное разыменование, а главное что без сюрпризов.

Ладно возвращаюсь к массивам.

И внимание! Речь пойдет только о массивах статических, выделенных на стэке. То есть о простых массивах типа int arr[n][m][k]

Попробую написать программку, в которой буду перебирать интересующие меня варианты работы с массивами через арифметику указателей.

Идея заключается в переборе вариантов с выводом типов и значений выражений.

```
Написал такую простыню:
```

```
#include <stdio.h>
#include <typeinfo>
#include <iostream>
int main(int argc, char* argv∏){
      int line[3] = \{1,2,3\};
      int \ square[2][2] = \{
             {1, 2},
             {3, 4}
      int \ cube[3][3][3] = \{
             {{1, 2, 3}, {4, 5, 6},{7, 8, 9}},
             {{10, 11, 12}, {13, 14, 15},{16, 17, 18}},
             {{19, 20, 21}, {22, 23, 24},{25, 26, 27}}
      };
      std::cout << "int line[3]; \land int square[2][2]; \land int cube[3][3][3]; "<< ' \land n';
      std::cout << "1: line has type: " << typeid(line).name() << '\n';</pre>
      std::cout << " square has type: " << typeid(square).name() << '\n';</pre>
      std::cout << " cube has type: " << typeid(cube).name() << '\n';</pre>
      std::cout << "2: &line has type: " << typeid(&line).name() << '\n';
      std::cout << " &square has type: " << typeid(&square).name() << '\n';</pre>
      std::cout << " &cube has type: " << typeid(&cube).name() << '\n';
      std::cout << "3: &line[0] has type: " << typeid(&line[0]).name() << '\n';
      std::cout << " &square[0][0] has type: " << typeid(&square[0][0]).name() << '\n';
      std::cout << " &cube[0][0][0] has type: " << typeid(&cube[0][0][0]).name() << '\n';
      std::cout << "3: *line has type: " << typeid(*line).name() << '\n';
      std::cout << " *square has type: " << typeid(*square).name() << '\n';
      std::cout << " *cube has type: " << typeid(*cube).name() << '\n';
      std::cout << '\n';
      printf("line == \%p \& line == \%p \& line[0] == \%p \ n", line, \& line, \& line[0]);
      &square[0][0]);
      [0][0]);
      std::cout << "cube has type: " << typeid(cube).name() << '\n';</pre>
      std::cout << "(cube+1) has type: " << typeid((cube+1)).name() << '\n';
      std::cout << ' \ n';
      return 0;
}
```

```
int line[3];
int square[2][2];
int cube[3][3][3];
1: line has type: A3_i
square has type: A2_A2_i
   cube has type: A3_A3_A3_i
2: &line has type: PA3_i
   &square has type: PA2_A2_i
   &cube has type: PA3_A3_A3 i
3: &line[0] has type: Pi
&square[0][0] has type: Pi
&cube[0][0][0] has type: Pi
3: *line has type: i
   *square has type: A2_i
   *cube has type: A3_A3_i
line == 000000000061FE34
                                                                &line[0] == 000000000061FE34
                               &line == 000000000061FE34
square == 000000000061FE20
                                 &square == 000000000061FE20
                                                                    &square[0][0] == 000000000061FE20
cube == 000000000061FDB0
                               &cube == 000000000061FDB0
                                                                &cube[0][0][0] == 0000000000061FDB0
cube has type: A3_A3_A3_i
(cube+1) has type: PA3_A3_i
```

Вывод программы:

Тааак. Интересно.

Буду рассуждать про *cube*, с остальными все обстоит так же.

Что же именно для меня интересно.

1. *cube* и &*cube* равны по значениям! Но ведь *cube* имеет <u>свой</u> адрес (как мы уже видели в отладчике)! Пусть будет 0х1000, тогда в памяти это бы выглядело так:

адрес : значение 0x1000 : 0x61FDB0

Но тогда *cube* должен быть равен 0x61FDB0, а & cube равен 0x1000.

А их значения равны. Но не типы. Операция & изменила тип, но значение не тронула.

Вывод: (это только мои рассуждения и все может быть полным бредом):

Операция & по отношению к имени массива компилятором рассматривается больше как приведение типа, чем взятие адреса.

С выражением &cube[0][0][0] все красиво. Первый элемент, берем адрес, получаем указатель.

- 2. Разные типы у cube и (cube+1). Это что за магия? Берем значение/адрес/не важно что прибавляем 1 и получаем другой тип данных???
- 3. *cube возвращает двумерный массив. Нет комментариев. Хотя если представить эту запись в другом виде *(cube + 0), то можно привести к пункту 2.

Из-за пунктов 2-3 я подвис. Да нет, не подвис. Впал в ступор. Хорошего объяснения я не нашел, для себя решил, что компилятор в тихую незаметно для нас выполняет приведение типов. В итоге он все оптимизирует и приводит к простому ассемблерному коду, как мы видели в отладчике. Но сами операции не очень прозрачны.

Полагаю все это сделано, чтобы для разработчика не было разницы при работе с динамическими или статическими массивами. Нужно только понимать, что при работе со статическим массивом, не все операции выполняются явным образом.

Жаль, что не хватило сил/желания/ума/времени разобраться досконально.

P.S. В порядке бреда. Где-то когда-то слышал (или статье читал), что компилятор при работе с массивом для многих операций приводит массив к указателю на первый элемент.

Если с этой точки зрения рассмотреть запись (cube + 1), mo

(&cube[0][0][0]+1), но 1 в этом случае не означает едицицу, на сколько же нужно отступить? Видимо компилятор предполагает, что ему нужно вернуть указатель на массив, в котором на 1 измерение меньше (т. е. из 2-мерного вернуть 1-мерный, из 3-мерного 2-мерный и т.д.).

Если принять, что так оно и есть, то итоговая запись для (cube + 1)

(int(*)[3][3])((char*)&cube[0][0][0] + 1 * sizeof(int[3][3])) и все вроде стало понятнее))).